S30 - Evidencia de aprendizaje 1. Análisis y herramientas de extracción de datos

Curso: Programación para Análisis de Datos

Profesor: Andrés Felipe Palacio Angel

Juan Esteban Acevedo Carvajal

Elaborado por:

Jairo Alexander Figueredo Chaparro

Cristian Palacio Muñoz

Jhorman Andres Palomeque Uribe

Institución Universitaria Digital de Antioquia

25/10/2026

Aplicación de la metodología de Web Scraping para la extracción de datos de productos en Alkosto Colombia

1. INTRODUCCIÓN

El comercio electrónico ha transformado la forma en que las empresas y los consumidores interactúan con la información. En la actualidad, los precios, la disponibilidad y las características de los productos cambian de manera constante, lo que hace inviable el monitoreo manual de grandes volúmenes de datos. En este contexto, el web scraping se presenta como una técnica fundamental para la extracción automatizada de información desde páginas web, permitiendo a las organizaciones tomar decisiones basadas en datos actualizados y competitivos.

El presente informe describe el proceso de aplicación de la metodología de scraping sobre la página de comercio electrónico Alkosto Colombia (https://www.alkosto.com), específicamente en la categoría de celulares. Para ello, se emplearon tres herramientas complementarias: BeautifulSoup, Selenium y Scrapy, cada una con un rol específico dentro del proceso de extracción. El objetivo es demostrar cómo estas tecnologías permiten obtener datos estructurados de un sitio real, superando las limitaciones que impone el contenido dinámico y las políticas de protección de datos.

2. DESCRIPCIÓN DE LA PÁGINA Y ARTÍCULO A ANALIZAR

Alkosto es una de las cadenas de retail más reconocidas en Colombia, con presencia en el comercio electrónico a través de su portal alkosto.com. La página ofrece una amplia variedad de productos, entre ellos electrodomésticos, tecnología, celulares y artículos para el hogar. Para esta práctica se seleccionó la categoría de celulares, accesible mediante la URL de búsqueda:

https://www.alkosto.com/search?text=celulares

El artículo principal de análisis es el Samsung Galaxy A37 256GB 5G Gris, que aparece como el primer resultado en la página de búsqueda. Este producto tiene un precio actual de $1.649.990** y un precio anterior de **$2.299.990, lo que representa un descuento del 28%. La selección de este artículo se debe a que es un producto representativo de la categoría y permite ilustrar la variación de precios y la competencia entre marcas como Samsung, Motorola, Xiaomi (Redmi), Oppo y Honor.

3. PLANTEAMIENTO DEL PROBLEMA

La extracción de datos desde páginas de comercio electrónico como Alkosto presenta varios desafíos técnicos. En primer lugar, los productos no están disponibles en el HTML estático: la página carga los datos de manera dinámica mediante JavaScript, lo que significa que una petición HTTP simple con requests no obtiene la información real. En segundo lugar, la estructura del DOM cambia con frecuencia, lo que obliga a validar los selectores constantemente. Finalmente, los sitios implementan mecanismos anti-bot que pueden bloquear las peticiones automatizadas.

Para abordar este problema, se emplearon tres métodos de web scraping de manera complementaria:

BeautifulSoup: se utilizó para el parseo del HTML estático. Aunque por sí solo no obtiene los datos dinámicos, permitió identificar la estructura base de la página y confirmar que los productos se cargan de forma asíncrona. Los selectores iniciales (div.product__item) encontraron 25 contenedores, pero vacíos, lo que evidenció la necesidad de una herramienta que renderizara JavaScript.

Selenium: se utilizó para renderizar la página en un navegador real (Chrome en modo headless). Gracias a Selenium se pudo esperar a que el JavaScript cargara los productos y luego extraer el HTML renderizado. Con los selectores correctos (.js-product-item, .js-algolia-product-title, .product__price--discounts__price), se obtuvieron los nombres y precios de los 10 primeros celulares.

Scrapy: se utilizó para estructurar un spider que define la lógica de crawling y extracción de datos. Aunque Alkosto requiere renderizado de JavaScript (por lo que Scrapy necesitaría scrapy-playwright para ejecutarse en producción), la definición del spider demuestra el dominio de la herramienta y su integración con los selectores identificados.

Pregunta de investigación: ¿Por qué analizar este artículo y esta empresa de comercio? Porque Alkosto es un referente del retail colombiano, y el Samsung Galaxy A37 es un producto de alta rotación cuya variación de precios y competencia con otras marcas (Motorola, Redmi, Oppo) ofrece un caso de estudio realista para aplicar técnicas de scraping. El análisis permite demostrar cómo la automatización puede facilitar el monitoreo de precios y la comparación de productos en un mercado dinámico.

4. OBJETIVOS

Objetivo general:
Aplicar la metodología de web scraping mediante las herramientas BeautifulSoup, Selenium y Scrapy para extraer datos de productos de la categoría de celulares en la página de comercio electrónico Alkosto Colombia.

Objetivos específicos:

Implementar BeautifulSoup para el parseo del HTML estático de la página de búsqueda de Alkosto, identificando las limitaciones del contenido dinámico.

Utilizar Selenium para renderizar la página y extraer los nombres y precios de los 10 primeros celulares disponibles.

Definir un spider de Scrapy que estructure la lógica de extracción de datos con los selectores identificados.

Analizar los resultados obtenidos y evaluar la efectividad de cada herramienta en el proceso de scraping.

5. METODOLOGÍA EMPLEADA DE SCRAPING

La metodología se desarrolló en cuatro fases, utilizando Google Colab como entorno de ejecución:

Fase 1: Configuración del entorno
Se instalaron las librerías necesarias (requests, beautifulsoup4, selenium, pandas, scrapy, google-colab-selenium) y se definieron los headers de navegador para simular peticiones reales.

Fase 2: Extracción con BeautifulSoup (contenido estático)
Se realizó una petición GET a la URL de búsqueda con requests. El HTML obtenido (1.730.036 caracteres) se parseó con BeautifulSoup. Se encontraron 25 contenedores div.product__item, pero todos con la clase skeleton y sin datos internos. Resultado: se confirmó que los productos se cargan dinámicamente y que BeautifulSoup por sí solo no es suficiente.

Fase 3: Extracción con Selenium (contenido renderizado)
Se utilizó google-colab-selenium para inicializar Chrome en modo headless con los flags adecuados para Colab. Se cargó la URL y se esperó explícitamente a que apareciera el selector .js-product-item (el contenedor real de los productos renderizados). Una vez cargados, se pasó el HTML renderizado a BeautifulSoup para extraer:

Nombre: selector .js-algolia-product-title, .product-info--name

Precio actual: selector .product__price--discounts__price, .js-priceProductA

Precio anterior: selector .product__price--discounts__old, .js-priceOldProductA

Fase 4: Definición del spider de Scrapy
Se definió la clase AlkostoSpider con start_urls apuntando a la URL de búsqueda y un método parse que recorre los .js-product-item y extrae los mismos campos. Se documentó que, para ejecutarlo en producción, se requeriría scrapy-playwright debido al renderizado JavaScript.

Métricas de éxito:

Tasa de detección de productos: 25/25 contenedores detectados (100%).

Tasa de extracción exitosa: 10/10 productos extraídos con nombre y precio (100%).

Tiempo de ejecución: < 30 segundos por extracción (Selenium).

Consistencia de datos: 100% de los precios extraídos coinciden con el formato $X.XXX.XXX.

6. RESULTADOS Y CONCLUSIONES
Resultados:
Se extrajeron exitosamente los 10 primeros productos de la categoría de celulares en Alkosto. La siguiente tabla resume los datos obtenidos:

#	Nombre del producto	Precio actual	Precio anterior
1	Celular SAMSUNG Galaxy A37 256GB 5G Gris	$1.649.990	$2.299.990
2	Celular SAMSUNG Galaxy A27 256GB 5G Negro	$1.089.050	$1.499.050
3	Celular SAMSUNG Galaxy A27 256GB 5G Azul	$1.089.050	$1.499.050
4	Celular OPPO A6 256GB 4G Azul	$1.149.900	$1.699.900
5	Celular MOTOROLA G67 256GB 5G Gris	$939.050	$1.899.050
6	Celular REDMI Note 17 Pro 256 5G Negro + Power Bank 165W	$1.699.050	$2.299.050
7	Celular SAMSUNG Galaxy A57 256GB 5G Morado	$1.999.990	$2.799.990
8	Celular REDMI Note 17 Pro 256 5G Morado + Power Bank 165W	$1.699.050	$2.299.050
9	Celular MOTOROLA G67 256GB 5G Verde Lima	$939.050	$1.899.050
10	Celular HONOR X5d 128GB 4G Negro	$549.050	$899.050

Conclusiones:

BeautifulSoup es útil para estructuras estáticas, pero insuficiente para sitios con contenido dinámico como Alkosto. Su valor en esta práctica fue confirmar la presencia de los contenedores y evidenciar la necesidad de renderizado.

Selenium es la herramienta clave para sitios con JavaScript. Permitió renderizar la página y extraer los datos reales, demostrando que la espera explícita por selectores específicos (.js-product-item) es fundamental para evitar capturar esqueletos de carga.

Scrapy ofrece una estructura robusta para proyectos de crawling a mayor escala. Aunque en esta práctica no se ejecutó completamente debido al renderizado JavaScript, la definición del spider demuestra su potencial para proyectos de extracción masiva.

La validación de selectores es un paso crítico: los selectores asumidos inicialmente (.product-info--name) no funcionaron; fue necesario inspeccionar el DOM renderizado para identificar las clases reales (.js-algolia-product-title, .product__price--discounts__price).

El scraping en sitios reales requiere adaptabilidad: Alkosto no bloqueó el acceso, pero sí exigió renderizado JavaScript. Esto demuestra que cada sitio impone desafíos específicos que deben abordarse con la herramienta adecuada.

7. BIBLIOGRAFÍA

Beautiful Soup Documentation. (2024). Beautiful Soup 4.12.3 documentation. https://www.crummy.com/software/BeautifulSoup/bs4/doc/

Google Colab. (2024). Google Colaboratory. https://colab.research.google.com/

Mozilla. (2024). Selenium WebDriver documentation. https://www.selenium.dev/documentation/

Scrapy. (2024). Scrapy 2.11 documentation.https://docs.scrapy.org/en/latest/

Selenium. (2024). Google Colab Selenium. https://pypi.org/project/google-colab-selenium/

Alkosto. (2024). Alkosto Tienda Online. https://www.alkosto.com/

ANEXO: Código fuente
Figueredo_Jairo_Analizando_EA1.ipynb