S35 - Evidencia de aprendizaje 2. Optimizando la productividad en el mundo del software

Curso: Programación para Análisis de Datos

Profesor: Andrés Felipe Palacio

Elaborado por:
Jairo Alexander Figueredo Chaparro
Cristian Palacio Muñoz
Jhorman Andrés Palomeque Uribe

Institución Universitaria Digital de Antioquia
10/11/2026

Implementación de un flujo de trabajo DevOps (Git y GitHub Actions) para la automatización de un scraper de precios en Alkosto Colombia

1. Introducción

En la Evidencia de Aprendizaje 1 se hizo el script de web scraping. Se utilizaron Python, BeautifulSoup, Selenium y Scrapy para extraer información de celulares de la página de Alkosto Colombia. En el mundo real del desarrollo de software, esto no es suficiente. Es necesario tener control de versiones, trabajar en equipo, realizar pruebas automatizadas y hacer deploy continuo.

En esta Evidencia de Aprendizaje 2 vamos a trabajar sobre el mismo proyecto de scraping. Vamos a aplicar la metodología DevOps. Utilizamos Git (con GitHub como alojamiento). Creamos un pipeline de Integración Continua y Despliegue Continuo (CI/CD) con GitHub Actions. Esto permite automatizar la ejecución del notebook. Los resultados de la extracción quedan como un artefacto descargable. De esta forma tenemos reproducibilidad del código y simulamos un entorno de trabajo en equipo profesional.

2. Descripción de la página y artículo analizado (Retomado de la EA1)

Alkosto es una de las cadenas de retail más reconocidas en Colombia. En el mundo digital cuenta con un portal web (alkosto.com) donde vende sus productos. Es así como podemos encontrar en esta plataforma una gran variedad de productos. Por ejemplo, en esta cadena encontramos productos de electrodomésticos, tecnología, celulares y productos para el hogar. Para este ejercicio nos enfocaremos en la categoría de celulares (https://www.alkosto.com/search?text=celulares).

En la primera posición de la página de resultados de búsqueda encontramos el artículo Samsung Galaxy A37 256GB 5G Gris. El precio actual de este artículo es de $1.649.990 (anteriormente tenía un precio de $2.299.990). Además de esto podemos ver que tiene un descuento de 28%. Hemos elegido este artículo porque es representativo de la categoría. También podemos observar cómo están posicionadas otras marcas en esta categoría (Samsung, Motorola, Xiaomi (Redmi), Oppo y Honor).

3. Tema de interés de la Evidencia de Aprendizaje 2

El eje de esta evidencia es el despliegue de un pipeline DevOps para la automatización de la ejecución y validación de un proyecto de extracción de datos. A diferencia de la EA1 donde se centraron en el aspecto meramente técnico (qué hacer para extraer los datos) en esta EA2 nos centramos en aspectos metodológicos e ingeniería de software. Es decir, cómo asegurar que nuestro código funciona bien cada vez que lo modificamos, cómo mantener un registro de los cambios realizados, cómo trabajar de manera colaborativa (usando ramas) y cómo automatizar la entrega de nuestros resultados.

4. Objetivos

Objetivo General:

Implementar un pipeline de CI/CD en GitHub Actions que integre pruebas automatizadas y despliegue continuo para el scraper de Alkosto, documentando el flujo de trabajo DevOps a través de un repositorio en GitHub.

Objetivos Específicos:

1. Utilizar Git y GitHub para gestionar el control de versiones del proyecto, empleando ramas (branches), confirmaciones (commits) con mensajes descriptivos y solicitudes de extracción (pull requests).

2. Configurar un workflow de GitHub Actions que instale las dependencias necesarias y ejecute el notebook de scraping de forma automática.

3. Establecer un mecanismo de despliegue continuo que publique el archivo CSV generado (con los datos extraídos) como un artifact descargable.

4. Documentar el proceso de integración y despliegue, así como las dificultades técnicas encontradas y su resolución.

5. Metodología Empleada (DevOps y Scraping)

La metodología se dividió en dos grandes fases: la implementación del control de versiones y la configuración del pipeline de integración y despliegue.

Fase 1: Control de Versiones con Git y GitHub

1. Creación del repositorio: Se creó un repositorio en GitHub (público) para alojar el notebook de la EA1 y el presente informe.

2. Commit inicial: Se subieron los archivos base a la rama principal (main) con un mensaje descriptivo (feat: subir evidencia EA1).

3. Creación de rama de trabajo: Se creó la rama feature/ci-cd-pipeline para desarrollar la configuración del pipeline sin afectar la rama principal, simulando un flujo de trabajo en equipo.

4. Pull Request (PR): Una vez realizados los cambios en la rama, se abrió un PR hacia main, el cual fue revisado automáticamente por el pipeline y posteriormente fusionado (merge).

Fase 2: Pipeline de CI/CD con GitHub Actions

Se creó el archivo .github/workflows/scraping-pipeline.yml en la raíz del proyecto. Este archivo define las acciones automáticas que se ejecutan en los servidores de GitHub cada vez que se hace un push o un pull_request. El pipeline consta de los siguientes pasos:

1. Checkout del código: Descarga el código del repositorio en el entorno de ejecución.

2. Configuración de Python: Prepara el entorno con Python 3.10.

3. Instalación de dependencias: Instala las librerías requeridas (requests, beautifulsoup4, selenium, pandas, scrapy, google-colab-selenium, jupyter, nbconvert).

4. Ejecución del notebook (Prueba Automatizada): Ejecuta el notebook mediante jupyter nbconvert --execute. Si el notebook falla (por ejemplo, si los selectores cambian), el pipeline falla y alerta al equipo.

5. Despliegue Continuo (Artifact): Toma el archivo alkosto_celulares.csv generado por el notebook y lo sube como un artifact para que pueda ser descargado desde la interfaz de GitHub.

Resolución de un error real: Durante el primer intento, el pipeline falló porque el archivo del notebook tenía un signo de exclamación (!) en lugar del número (1) en su nombre, lo cual generó un conflicto en el entorno Linux de GitHub. Se renombró el archivo y se actualizó el repositorio, logrando que el pipeline se ejecutara exitosamente.

6. Resultados y Conclusiones

Resultados:

1. Se logró implementar un flujo de trabajo completo en GitHub, evidenciado por el historial de commits y la fusión del Pull Request.

2. El pipeline de CI/CD se ejecutó de manera exitosa en 1 minuto y 3 segundos, pasando todas las verificaciones (All checks have passed).

3. Se generó y publicó el artifact datos-alkosto-csv, confirmando el despliegue continuo de los resultados.

Conclusiones:

1. DevOps añade valor al scraping: Un script de extracción de datos aislado es frágil; al integrarlo en un pipeline, se garantiza que siempre funcione con las dependencias correctas.

2. GitHub Actions es una herramienta poderosa y gratuita: Permite automatizar pruebas y despliegues sin necesidad de configurar servidores propios.

3. La importancia del control de versiones: El uso de ramas y pull requests permite que los equipos trabajen en paralelo y detecten errores antes de integrar el código final.

4. Resolución de problemas: El error del nombre del archivo demostró la importancia de estandarizar nomenclaturas en entornos de integración.

7. Bibliografía

GitHub. (2024). GitHub Actions Documentation. https://docs.github.com/en/actions

Jupyter. (2024). nbconvert documentation. https://nbconvert.readthedocs.io/

Selenium. (2024). Google Colab Selenium. https://pypi.org/project/google-colab-selenium/

Alkosto. (2024). Alkosto Tienda Online. https://www.alkosto.com/

8. Anexo:

Código del Pipeline (scraping-pipeline.yml)

```
None
name: Pipeline de Scraping Alkosto

on:
  push:
    branches: [ main, feature/ci-cd-pipeline ]
  pull_request:
    branches: [ main ]

jobs:
  ejecutar-scraping:
    runs-on: ubuntu-latest
    steps:
      - name: Checkout del código
        uses: actions/checkout@v4

      - name: Configurar Python
        uses: actions/setup-python@v5
        with:
          python-version: '3.10'

      - name: Instalar dependencias
        run: |
          pip install requests beautifulsoup4 selenium pandas scrapy
google-colab-selenium
          pip install jupyter nbconvert

      - name: Ejecutar el notebook (Prueba automatizada)
        run: |
          jupyter nbconvert --to notebook --execute
"Figueredo_Jairo_Analizando_EA1.ipynb" --output "notebook_ejecutado.ipynb"
--ExecutePreprocessor.timeout=600
```

```
    - name: Subir el CSV como Artifact (Despliegue)
      uses: actions/upload-artifact@v4
      with:
        name: datos-alkosto-csv
        path: alkosto_celulares.csv
```

Link del repositorio:
https://github.com/Ingjairofigue/scraping-alkosto-devops.git